

Stacjonarność

ASC 2026

Piotr Żoch

- Regresja pozorną.
- Funkcje ACF i PACF.
- Badanie stacjonarności: testy DF, ADF, KPSS.

Regresja pozorná

- **Regresja pozorna** (*spurious regression*): zmienne (x_t, y_t) nie mają ze sobą żadnego związku, ale uzyskujemy statystycznie istotne oszacowania.
- Klasyczny przykład: regresja jednej zmiennej niestacjonarnej na drugą, obie to błądzenie losowe.

$$x_t = x_{t-1} + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

$$y_t = y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

$$y_t = \beta x_t + e_t$$

- Objawy regresji pozornej:
 - Wysoka wartość statystyki testowej (p -value niskie).
 - Wysokie R^2 .
 - Silna autokorelacja reszt.
 - Zmiana wyniku po dodaniu opóźnionej zmiennej objaśniającej (brak statystycznej istotności).

- Dlaczego tak się dzieje?
- Problem:
 - Rozkłady statystyk testowych są niestandardowe (czyli błędem jest badanie istotności zmiennych przy założeniu normalności rozkładu statystyki).
- Estymator OLS nie jest zgodny.
 - nie będzie zbiegać do 0 (prawdziwej wartości w przykładzie powyżej) przy zwiększeniu liczby obserwacji.

- Przykład: błędzenie losowe z dryfem

$$x_t = \mu_x + x_{t-1} + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

$$y_t = \mu_y + y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

- Zauważmy, że

$$x_t = \mu_x t + \sum_{k=1}^t \epsilon_k + x_0$$

$$y_t = \mu_y t + \sum_{k=1}^t \nu_k + y_0$$

Regresja pozorna: przykład

- Mamy (dla modelu bez wyrazu wolnego)

$$\hat{\beta} = \frac{\sum_{t=1}^T x_t y_t}{\sum_{t=1}^T x_t^2} = \frac{\sum_{t=1}^T (\mu_x t + \sum_{k=1}^t \epsilon_k + x_0) (\mu_y t + \sum_{k=1}^t \nu_k + y_0)}{\sum_{t=1}^T (\mu_x t + \sum_{k=1}^t \epsilon_k + x_0)^2}$$

- Aby to uprościć, użyjemy

$$\frac{1}{T^2} \sum_{t=1}^T t \rightarrow \frac{1}{2}$$

$$\frac{1}{T^3} \sum_{t=1}^T t^2 \rightarrow \frac{1}{3}$$

Regresja pozorna: przykład

- Mamy

$$\hat{\beta} = \frac{\frac{1}{T^3} \sum_{t=1}^T (\mu_x t + \sum_{k=1}^t \epsilon_k + x_0) (\mu_y t + \sum_{k=1}^t \nu_k + y_0)}{\frac{1}{T^3} \sum_{t=1}^T (\mu_x t + \sum_{k=1}^t \epsilon_k + x_0)^2}$$
$$\xrightarrow{P} \frac{\mu_y}{\mu_x}$$

- *Uwaga:* w tym przykładzie za regresję pozorną odpowiadały wyrazy zawierające t^2 , czyli trend deterministyczny – podobne problemy będziemy mieli przy zmiennych trendostacjonarnych.
- *Uwaga:* podobne problemy występują też w przypadku błędzenia losowego, ale trochę trudniej to pokazać analitycznie.

Regresja pozorna: przykład

- Co w przypadku regresji liniowej

$$x_t = \beta y_t + \gamma x_{t-1} + e_t?$$

- Różnica: uwzględniliśmy x_{t-1} jako zmienną objaśniającą.
- Okazuje się, że to rozwiązuje problem regresji pozornej (wyjaśnienie przy zajęciach dot. kointegracji).
- Praktyczna sugestia: dodać opóźnienia x_t i y_t w regresji.

Funkcje ACF i PACF

- **Funkcja autokorelacji** (*Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}$$

i $\rho_k \in [-1, 1]$.

- Użyliśmy $\sqrt{\text{Var}(y_t) \text{Var}(y_{t-k})} = \text{Var}(y_t)$ (to wymaga stacjonarności).

- **Funkcja autokorelacji cząstkowej** (*Partial Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami oddalonymi od siebie o k okresów **bez** uwzględnienia wpływu wszystkich obserwacji “pomiędzy”.
- Funkcja ta jest równa wyestymowanemu współczynnikowi α_k w modelu autoregresyjnym k -tego rzędu

$$y_t = \mu + \alpha_1 y_{t-1} + \cdots + \alpha_k y_{t-k} + \varepsilon_t$$

Test Breuscha-Godfrey

- Służy do badania autokorelacji reszt z regresji liniowej

$$y_t = \beta_0 + \beta_1 x_{1,t} + \dots + \beta_n x_{n,t} + e_t$$

$$e_t = \rho_1 e_{t-1} + \rho_2 e_{t-2} + \dots + \rho_k e_{t-k} + \varepsilon_t$$

- Wartość statystyki testowej TR^2 , gdzie R^2 jest z regresji pomocniczej

$$\hat{e}_t = \alpha_0 + \sum_{j=1}^n \alpha_j x_{j,t} + \sum_{i=1}^k \rho_i \hat{e}_{t-i} + \varepsilon_t$$

(gdzie $x_{j,t}$ to te same zmienne co w głównej regresji).

- $H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$. Rozkład to $TR^2 \sim \chi_k^2$.

$$Q = T(T+2) \sum_{i=1}^k \frac{\hat{\rho}_i^2}{T-i}$$
$$\sim \chi_k^2$$

- H_0 : brak autokorelacji do rzędu k (w praktyce: reszty jak biały szum).
- Test standardowy w diagnostyce reszt modeli ARMA/ARIMA.
- W tym kursie, przy ręcznie estymowanej regresji ADF, lepszy jest test Breuscha-Godfrey (warunkuje na regresorach modelu).

Badanie stacjonarności

- Najpopularniejszy sposób badania stacjonarności zmiennych.
- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$
$$\varepsilon_t \sim iid(0, \sigma^2)$$

- H_0 : proces jest błądzeniem losowym ($\beta = 1$) – niestacjonarność.
- H_1 : proces jest procesem AR(1) ($|\beta| < 1$) – stacjonarność.

- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma^2)$$

- Odejmując y_{t-1} od obu stron:

$$\Delta y_t = (\beta - 1) y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

- $H_0: \rho = 0$ – niestacjonarność.
- $H_1: \rho < 0$ (w teorii $\rho \in (-2, 0)$) – stacjonarność.

Test Dickeya-Fullera: rozkład statystyki

- Dlaczego rozkład statystyki t jest niestandardowy?
- Rozważmy model $y_t = y_{t-1} + \varepsilon_t$ (czyli $\beta = 1$). Estymator OLS dla β to:

$$\hat{\beta} = \frac{\sum_{t=1}^T y_{t-1} y_t}{\sum_{t=1}^T y_{t-1}^2}$$

- Można pokazać, że:

$$T(\hat{\beta} - 1) = \frac{\frac{1}{T} \sum_{t=1}^T y_{t-1} \varepsilon_t}{\frac{1}{T^2} \sum_{t=1}^T y_{t-1}^2}$$

- Licznik i mianownik nie zbiegają do stałych (jak w klasycznym OLS), lecz do zmiennych losowych będących funkcjami procesu Wienera (ruchu Browna).

Proces Wienera (Ruch Browna)

- Proces Wienera $W(r)$ dla $r \in [0, 1]$ to proces stochastyczny o czasie ciągłym, taki że:
 - $W(0) = 0$.
 - Dla $0 \leq r_1 < r_2 \leq 1$: $W(r_2) - W(r_1) \sim N(0, r_2 - r_1)$.
 - Przyrosty na rozłącznych przedziałach są niezależne.
- Zbieżność (twierdzenie Donskera): jeśli $y_t = \sum_{i=1}^t \varepsilon_i$, gdzie $\varepsilon_i \sim iid(0, \sigma^2)$, to dla $r \in [0, 1]$:

$$\frac{1}{\sigma\sqrt{T}} y_{\lfloor rT \rfloor} \xrightarrow{d} W(r)$$

- W konsekwencji, mianownik i licznik statystyki $T(\hat{\beta} - 1)$ zbiegają do:

$$\frac{1}{T^2} \sum_{t=1}^T y_{t-1}^2 \xrightarrow{d} \sigma^2 \int_0^1 W(r)^2 dr,$$
$$\frac{1}{T} \sum_{t=1}^T y_{t-1} \varepsilon_t \xrightarrow{d} \frac{1}{2} \sigma^2 (W(1)^2 - 1).$$

- Stąd rozkład graniczny:

$$T(\hat{\beta} - 1) \xrightarrow{d} \frac{\frac{1}{2} (W(1)^2 - 1)}{\int_0^1 W(r)^2 dr}$$

- Jest to rozkład Dickeya-Fullera – asymetryczny i skośny w lewo.

- **UWAGA:** nie możemy po prostu zastosować OLS i za pomocą statystyki t zbadać istotność w standardowy sposób.
 - H_0 : niestacjonarność. Rozkłady statystyk są niestandardowe!
- Wykorzystujemy specjalne tablice z wartościami krytycznymi dla testu DF.
- Uwaga techniczna: wielkości krytyczne rozkładu statystyki DF są zawsze ujemne.

- Procedura:
 - Regresja Δy_t na y_{t-1} .
 - Porównujemy statystykę t z wartościami krytycznymi testu DF:
 - t **poniżej** wartości krytycznej: odrzucamy H_0 (stacjonarność?).
 - t **powyżej** wartości krytycznej: nie odrzucamy H_0 (niestacjonarność?).

- Błądzenie losowe z dryfem:

$$y_t = \alpha_1 + \beta y_{t-1} + \varepsilon_t$$

- Trend deterministyczny:

$$y_t = \alpha_1 + \alpha_2 t + \beta y_{t-1} + \varepsilon_t$$

- We wszystkich powyższych przypadkach H_0 to też niestacjonarność.

Rozszerzony test DF (ADF)

- Reszty z regresji

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

często wykazują silną autokorelację.

- Rozszerzony test DF (augmented DF):

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \varepsilon_t$$

gdzie k jest dobrane tak, żeby wyeliminować autokorelację reszt.

- Procedura:
 - Regresja Δy_t na y_{t-1} .
 - Sprawdzamy autokorelację reszt (test Breuscha-Godfrey, nie Durbina-Watsona) – w tej procedurze to podejście preferowane.
 - Jeśli jest, dodajemy kolejne opóźnione różnice Δy_{t-k} do specyfikacji i powtarzamy.
 - W przeciwnym wypadku:
 - t **poniżej** wartości krytycznej: odrzucamy H_0 (stacjonarność?).
 - t **powyżej** wartości krytycznej: nie odrzucamy H_0 (niestacjonarność?).

Test ADF w praktyce: wybór k

- Jak dobrać k ?
 - Podejście sekwencyjne (*od ogólnego do szczegółowego*): zaczynamy od $k_{\max}$, usuwamy kolejne opóźnienia, jeśli nieistotne.
 - Kryteria informacyjne: minimalizujemy AIC lub BIC po k .
- Uwaga: zbyt małe $k \rightarrow$ autokorelacja reszt $\rightarrow$ błędne wnioskowanie.
- Uwaga: zbyt duże $k \rightarrow$ utrata stopni swobody $\rightarrow$ spadek mocy testu.
- W praktyce $k_{\max}$ dobiera się według reguły $k_{\max} = \lfloor 12 \cdot (T/100)^{1/4} \rfloor$ (Schwert, 1989).
- Wzór ten jest domyślny w wielu pakietach, ale dla danych kwartalnych/rocznych często stosuje się mniejszą bazę (np. $4 \cdot (T/100)^{1/4}$).

- Perron (1989) pokazał, że test ADF ma problemy z odrzuceniem hipotezy zerowej o występowaniu pierwiastka jednostkowego w przypadku zmiany strukturalnej.
- Dla przykładu: proces typu

$$y_t = \beta D_t + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma^2)$$

$$D_t = \begin{cases} 0 & t < t^* \\ 1 & t \geq t^* \end{cases}$$

- Perron (1989) sugeruje modyfikację testu ADF:

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \beta D_t + \varepsilon_t$$

- Wymaga to znajomości daty zmiany strukturalnej.
- Modyfikacja: Zivot i Andrews (1992) – poszukiwanie takiej daty zmiany strukturalnej, że moc testu jest największa.

- Model:

$$y_t = x_t + z_t$$

$$x_t = x_{t-1} + v_t$$

$$z_t = \mu_0 + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$$

$$v_t \sim iid(0, \sigma_v^2)$$

- $H_0: \sigma_v^2 = 0$ – stacjonarność (wtedy $x_t = x_0 = \text{const}$).
- $H_1: \sigma_v^2 > 0$ – niestacjonarność.

- Procedura:
 - Regresja y_t na stałą (+ ew. trend deterministyczny).
 - Obliczyć sumy $S_t = \sum_{j=1}^t e_j$ dla $t = 1, 2, 3, \dots, T$, gdzie e_j to reszty z regresji powyżej.
 - Statystyka testowa: $KPSS = \frac{1}{T^2} \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}^2}$, gdzie $\hat{\sigma}^2$ to długookresowa wariancja reszt.

Test KPSS: długookresowa wariancja

- Reszty e_t mogą być autokorelowane, więc zwykły estymator $\frac{1}{T} \sum e_t^2$ jest obciążony.
- Długookresowa wariancja: $\sigma_{LR}^2 = \sum_{j=-\infty}^{\infty} \gamma_j = \gamma_0 + 2 \sum_{j=1}^{\infty} \gamma_j$, gdzie $\gamma_j = \text{Cov}(e_t, e_{t-j})$.
- Estymator jądrowy (HAC): $\hat{\sigma}_{LR}^2 = \hat{\gamma}_0 + 2 \sum_{j=1}^l k\left(\frac{j}{l}\right) \hat{\gamma}_j$, gdzie $k(\cdot)$ to funkcja jądrowa, a l to szerokość okna (*bandwidth*).
- Najpopularniejszy: estymator Newey-Westa (1987) z jądrem Bartletta $k(x) = 1 - x$ (często używa się też wagi $1 - \frac{j}{l+1}$).
- Dobór l wpływa na wyniki – zbyt małe l prowadzi do nadodrzucania H_0 (zaburzenia rozmiaru).

Testowanie (nie)stacjonarności

- W przypadku małej próby i procesów o wysokim stopniu persystencji:
 - Test ADF: niska moc.
 - Test KPSS: zaburzenia rozmiaru.
- Przykład: jak odróżnić proces trendostacjonarny

$$y_t = \alpha t + \epsilon_t$$

od błędzenia losowego z dryfem

$$\begin{aligned} y_t &= \mu + y_{t-1} + \epsilon_t \\ &= y_0 + \mu t + \sum_{i=1}^t \epsilon_i \end{aligned}$$

- Czy to, czy proces jest stacjonarny czy niestacjonarny, ma znaczenie?
- Teoria ekonomii może być bardziej pomocna od testów statystycznych...

- Jaki test wybrać? Jakie deterministyczne regresory uwzględnić?
- Problem:
 - dodatkowe deterministyczne komponenty w regresji, które są nieobecne w procesie generującym dane, redukują stopnie swobody i obniżają moc testu stacjonarności.
 - pominięcie deterministycznych komponentów w regresji, które są obecne w procesie generującym dane, obniża moc testu.

