

Dekompozycja szeregów czasowych


ASC 2026

Piotr Żoch


- Składowe szeregów czasowych.
- Dekompozycja addytywna i multiplikatywna.
- Obserwacje nietypowe.
- Średnie ruchome.
- Metody wyrównywania sezonowego: X-13, TRAMO/SEATS, STL.

Składowe szeregów czasowych

Składowe szeregów czasowych



Składowe szeregów czasowych




- Składowa przypadkowa.
- Składowa systematyczna (efekt oddziaływań stałego zestawu czynników na zmienną prognozowaną):
 - Trend (tendencja rozwojowa).
 - Stały poziom (przeciętny długookresowy poziom zmiennej).
 - Składowa okresowa:
 - Wahania sezonowe.
 - Wahania cykliczne.

Składowe szeregów czasowych

- **Tendencja rozwojowa (trend)**
 - Długookresowa skłonność do jednokierunkowych zmian (wzrostu lub spadku) wartości badanej zmiennej.
- **Stały (przeciętny) poziom**
 - Występuje, gdy w szeregu czasowym nie ma tendencji rozwojowej, wartości zmiennej prognozowanej oscylują zaś wokół pewnego (stałego poziomu).
- **Wahania cykliczne**
 - Długookresowe rytmiczne wahania wartości wokół tendencji rozwojowej lub stałego (przeciętnego) poziomu.
- **Wahania sezonowe**
 - Wahania wartości obserwowanej zmiennej wokół tendencji rozwojowej lub stałego (przeciętnego) poziomu tej zmiennej. Mają skłonność do powtarzania się w określonym czasie.

Składowe szeregów czasowych



- Wyodrębnienie poszczególnych składników nie zawsze jest łatwe z uwagi na rozmaite interakcje, które zachodzą pomiędzy nimi.
- Różne metody dekompozycji (średnie ruchome, wydzielanie komponentów o różnej częstotliwości, procedury TRAMO/SEATS itd).

Trend i sezonowość

- Trend
 - **deterministyczny**

$$y_t = \alpha + \beta t + \epsilon_t$$

$$y_t = \alpha + \beta t + \gamma t^2 + \epsilon_t$$

$$y_t = \kappa e^{\delta t} e^{\epsilon_t}$$


$$\epsilon_t \sim iid(0, \sigma_\epsilon^2)$$

- **stochastyczny**


$$y_t = \alpha + y_{t-1} + \epsilon_t$$

$$\epsilon_t \sim iid(0, \sigma_\epsilon^2)$$

Trend



- W praktyce rozróżnienie może nie być łatwe...



- Dwa typy sezonowości:
 - **Deterministyczna**
 - Wartości obserwacji szeregu cechującego się sezonowością deterministyczną wahają się z amplitudą względnie stałą.
 - Proces, którego bezwarunkowa średnia zależy od podokresu roku (np. miesiąca, kwartału).
 - Ten rodzaj sezonowości jest modelowany za pomocą zmiennych zerojedynkowych, ich liczba zależy od liczby okresów w roku.
 - **Stochastyczna**
 - Charakteryzuje się zmiennym w czasie wzorcem sezonowości.

- Deterministyczna sezonowość (przykład):

$$y_t = \sum_{s=1}^S \delta_{t,s} m_s + \epsilon_t$$

$\delta_{t,s} = 1$ jeśli okres t przypada na sezon s (np. $\delta_{t,12} = 1$ jeśli okres t to grudzień w przypadku danych miesięcznych).

- Stochastyczna sezonowość (przykład – sezonowy pierwiastek jednostkowy):

$$y_t = y_{t-S} + \epsilon_t$$

Dekompozycja addytywna i multiplikatywna

- Punktem wyjścia jest założenie, że szereg czasowy można zdekomponować na elementy:
 - **czynnik sezonowy** S_t – regularne fluktuacje sezonowe;
 - **cykl i trend** C_t – długookresowy trend, cykl koniunkturalny i inne składniki cykliczne;
 - **trading-day** TD_t – kształt kalendarza – korekta ze względu na różną długość miesięcy, liczbę dni roboczych itp.;
 - **składnik losowy** I_t .
- Chcemy uzyskać dane wyrównane sezonowo SA_t .

- Postać addytywna

$$Y_t = S_t + C_t + TD_t + I_t$$

$$SA_t = C_t + I_t$$

czyli amplituda wahań sezonowych i losowych jest stała.

- Czynniki sezonowy S_t wyraża się w jednostkach zmiennej Y_t (np. mld PLN).
- Warunek normalizacji: $\sum_{s=1}^S S_{t_s} = 0$ w obrębie każdego roku.

- Postać multiplikatywna



$$Y_t = S_t \times C_t \times TD_t \times I_t$$

$$SA_t = C_t \times I_t$$










czyli amplituda wahań sezonowych i losowych zależy od trendu.

- Czynniki sezonowy S_t jest bezwymiarowy (np. $S_t = 1,05$ oznacza, że wartość w tym sezonie jest o 5% wyższa od trend-cyklu).
- Warunek normalizacji: $\sum_{s=1}^S S_{t_s} = S$ (średnia równa 1).

Postać addytywna vs postać multiplikatywna



Postać addytywna vs postać multiplikatywna

Sezonowość → Trend ↓	Brak	Sezonowość addytywna	Sezonowość multiplikatywna
Brak			
Trend addytywny			
Trend multiplikatywny			

- Model multiplikatywny można sprowadzić do addytywnego stosując logarytm:

$$Y_t = S_t \times C_t \times I_t$$

$$\ln Y_t = \ln S_t + \ln C_t + \ln I_t$$

- Dlatego w praktyce często pracujemy na zlogarytmowanych danych.
- Dodatkowa zaleta: logarytm stabilizuje wariancję (jeśli wariancja rośnie proporcjonalnie do poziomu zmiennej).
- W kontekście wyrównywania sezonowego: wybór między dekompozycją addytywną a multiplikatywną jest jedną z pierwszych decyzji w procedurze.

Obserwacje nietypowe

- **O charakterze jednorazowym** (*additive outlier (AO)*) powodujące zmianę wartości zmiennej zależnej tylko w jednym okresie

$$AO_t^{(t_0)} = \begin{cases} 1 & t = t_0 \\ 0 & t \neq t_0 \end{cases}$$

- Wpływ na szereg (addytywnie): $y_t = f(t) + \omega \cdot AO_t^{(t_0)} + \varepsilon_t$, gdzie ω to wielkość zaburzenia.

- **O charakterze przejściowym** (*temporary change (TC)*), powodujące tymczasowe przesunięcie poziomu zmiennej zależnej, przy czym powrót ze skokowej zmiany wartości zmiennej zależnej do poziomu pierwotnego następuje zgodnie z funkcją wykładniczą w postaci

$$TC_t^{(t_0)} = \begin{cases} 0 & t < t_0 \\ \alpha^{t-t_0} & t \geq t_0 \end{cases}$$

gdzie $\alpha \in (0, 1)$ kontroluje szybkość powrotu (typowo $\alpha = 0,7$).

- O charakterze długotrwałym (*level shift (LS)*), powodujące trwałe przesunięcie poziomu zmiennej zależnej

$$LS_t^{(t_0)} = \begin{cases} 0 & t < t_0 \\ 1 & t \geq t_0 \end{cases}$$

- W modelach regARIMA (TRAMO, X-13) obserwacje nietypowe są identyfikowane automatycznie i uwzględniane jako zmienne objaśniające:

$$y_t = \sum_i \omega_i \cdot O_t^{(t_i)} + \underbrace{x_t' \beta}_{\text{regARIMA}} + z_t + \varepsilon_t$$

Średnie ruchome

- Symetryczna średnia ruchoma rzędu $2q + 1$:

$$\hat{C}_t = \sum_{j=-q}^q w_j y_{t-j}$$

gdzie $w_j = w_{-j}$ oraz $\sum_j w_j = 1$.

- Aby wyeliminować sezonowość o okresie S , stosujemy średnią ruchomą o długości S (np. 12 dla danych miesięcznych, 4 dla kwartalnych).
- Dla parzystego S stosujemy średnią $2 \times S$:

$$\hat{C}_t = \frac{1}{S} \left(\frac{1}{2} y_{t-S/2} + y_{t-S/2+1} + \cdots + y_{t+S/2-1} + \frac{1}{2} y_{t+S/2} \right)$$

Średnie ruchome: właściwości

- Średnia ruchoma to **filtr liniowy**: przekształca szereg wejściowy $\{y_t\}$ na wyjściowy $\{\hat{C}_t\}$ za pomocą wag $\{w_j\}$.
- Średnia ruchoma o długości S **eliminuje składową sezonową** o okresie S : jeśli S_t jest periodyczna z okresem S i $\sum_{s=1}^S S_{t_s} = 0$, to

$$\frac{1}{S} \sum_{j=0}^{S-1} S_{t-j} = 0$$

- Jednocześnie zachowuje trend: jeśli $C_t = a + bt$, to $\hat{C}_t = a + bt$ (dla symetrycznych wag sumujących się do 1).
- Problem: średnia ruchoma nie daje wartości na końcach próby (brak obserwacji przyszłych) – tu właśnie pomagają model ARIMA w X-13.

- W metodzie X-12/X-13 do estymacji trendu używa się **filtru Hendersona**, a nie prostej średniej ruchomej.
- Filtr Hendersona minimalizuje $\sum_t \left(\nabla^3 \hat{C}_t \right)^2$, tj. sumę kwadratów trzeciej różnicy estymowanego trendu.
- Formalne sformułowanie: szukamy wag $\{w_j\}_{j=-q}^q$ rozwiązujących

$$\min_{\{w_j\}} \sum_t \left(\Delta^3 \hat{C}_t \right)^2 \quad \text{p.w.} \quad \sum_j w_j = 1, \quad \sum_j j^k w_j = 0 \quad \text{dla } k = 1, 2$$

- Typowe długości filtra: 9 lub 13 (dane miesięczne), 5 lub 7 (dane kwartalne).
- Wybór długości zależy od stosunku zmienności komponentu nieregularnego do zmienności trend-cyklu (*I/C ratio*).

Metody wyrównywania sezonowego

- Dwie popularne metody to:
 - **X-12-ARIMA** (obecnie X-13-ARIMA-SEATS)
 - **TRAMO/SEATS**
- Obie dostępne w programie **JDemetra+** (opracowany przez Eurostat, darmowy).

- Program składa się z dwóch etapów:
 1. **regARIMA** – wstępne oczyszczenie szeregu (patrz następny slajd).
 2. **X-11** lub **SEATS** – właściwa dekompozycja na komponenty.
- Kolejność: najpierw regARIMA usuwa z szeregu efekty kalendarzowe i obserwacje nietypowe, a następnie X-11 lub SEATS dekomponuje oczyszczony szereg.

- Model regARIMA to model regresji, w którym reszty mają strukturę SARIMA:

$$y_t = \underbrace{x_t' \beta}_{\text{regresory}} + \underbrace{z_t}_{\text{reszty SARIMA}}$$

- Regresory x_t mogą obejmować: zmienne sezonowe, efekty kalendarzowe (trading-day, Wielkanoc), obserwacje nietypowe (AO, TC, LS).
- Reszty z_t spełniają model SARIMA:

$$\phi(B) \Phi(B^S) (1 - B)^d (1 - B^S)^D z_t = \theta(B) \Theta(B^S) \varepsilon_t$$

- Po estymacji modelu obliczamy **zlinearyzowany szereg**: $\tilde{y}_t = y_t - x_t' \hat{\beta}$, który trafia do X-11 lub SEATS.
- Model SARIMA służy też do **prognozowania** wartości na końcach próby (potrzebnych do filtrów symetrycznych).

X-11: algorytm iteracyjny

- Metoda ad hoc, dobór filtrów nie zależy od właściwości statystycznych szeregu.
- Nieco myląca nazwa – model ARIMA jest wykorzystywany jedynie do estymacji wartości prognozowanych.
 1. Trend obliczany za pomocą średnich ruchomych (filtr 2×12 lub 2×4).
 2. Odjęć trend od szeregu, pozostaje komponent sezonowy i nieregularny:
$$\hat{S}_t + \hat{I}_t = Y_t - \hat{C}_t.$$
 3. Komponent sezonowy obliczany za pomocą średnich ruchomych (sezonowe 3×3 , 3×5 lub 3×9).
 4. Odjęć komponent sezonowy od szeregu: $\hat{S}A_t = Y_t - \hat{S}_t.$
 5. Ponowić (1) i (2) z filtrem Hendersona dla trendu.
 6. Ponowić (3) i (4) z nieco innymi wagami.
 7. Otrzymać trend i komponent nieregularny odejmując uzyskany w (6) komponent sezonowy od szeregu.

X-11: filtry sezonowe

- W kroku (3) stosujemy **sezonowe średnie ruchome**: osobna średnia ruchoma dla każdego miesiąca/kwartału.
- Np. filtr 3×3 dla danych miesięcznych: dla każdego miesiąca s uśredniamy wartości $(S_t + I_t)$ z trzech kolejnych lat:

$$\hat{S}_t^{(s)} = \frac{1}{9} \left(y_{t-24}^{SI} + 2y_{t-12}^{SI} + 3y_t^{SI} + 2y_{t+12}^{SI} + y_{t+24}^{SI} \right)$$

gdzie $y_t^{SI} = Y_t - \hat{C}_t$.

- Następnie normalizacja: $\hat{S}_t \leftarrow \hat{S}_t - \bar{\hat{S}}$ (addytywnie) lub $\hat{S}_t \leftarrow \hat{S}_t / \bar{\hat{S}}$ (multiplikatywnie).
- Wybór filtra (3×3 , 3×5 , 3×9) zależy od stabilności wzorca sezonowego: im bardziej zmienny, tym krótszy filtr.

- **TRAMO** (“Time Series Regression with ARIMA Noise, Missing Observations and Outliers”): dopasowuje proces SARIMAX do szeregu i oczyszcza szereg z wpływu wybranych czynników X (kalendarzowych, nietypowych. . .) za pomocą tego modelu.
- **SEATS** (“Seasonal Extraction in ARIMA Time Series”): korzysta ze specyfikacji SARIMA, by zdekomponować szereg na elementy: trendu, sezonowości, nieregularny.

SEATS: dekompozycja oparta na modelu

- Załóżmy, że zlinearyzowany szereg ma model SARIMA:

$$\phi(B) \Phi(B^S) (1 - B)^d (1 - B^S)^D y_t = \theta(B) \Theta(B^S) \varepsilon_t$$

- SEATS dekomponuje to na **nieobserwowalne komponenty**:

$$y_t = C_t + S_t + I_t$$

gdzie każdy komponent ma własny model ARIMA, np.:

$$\begin{aligned}\phi_C(B) (1 - B)^d C_t &= \theta_C(B) \varepsilon_t^C \\ \phi_S(B) (1 - B^S)^D S_t &= \theta_S(B) \varepsilon_t^S\end{aligned}$$

- Ekstrakcja sygnału za pomocą **filtrów Wienera-Kołmogorowa** – optymalnych filtrów liniowych minimalizujących błąd średniokwadratowy.
- Intuicja: mając model ARIMA całego szeregu i modele poszczególnych komponentów, możemy obliczyć optymalną estymację każdego komponentu warunkując na obserwacjach $\{y_1, \dots, y_T\}$:

$$\hat{C}_t = E[C_t \mid y_1, \dots, y_T]$$

- Filtry te są **wyznaczone przez model ARIMA** – nie wymagają arbitralnych wyborów (jak długość filtra w X-11).
- Kluczowa różnica wobec X-11: filtry dostosowane do właściwości statystycznych konkretnego szeregu (a nie ad hoc).

X-11 vs SEATS: porównanie

- **X-11:**
 - Metoda nieparametryczna (filtry ad hoc).
 - Nie wymaga specyfikacji modelu.
 - Sprawdzona, stabilna procedura (używana od lat 60.).
- **TRAMO/SEATS:**
 - Metoda parametryczna (oparta na modelu SARIMA).
 - Filtry optymalne w sensie MSE.
 - Dostarcza błędy standardowe komponentów.
- W praktyce wyniki obu metod są zazwyczaj bardzo zbliżone.
- X-13-ARIMA-SEATS łączy obie metody w jednym programie.

- **STL** (*Seasonal and Trend decomposition using Loess*) – Cleveland et al. (1990).
- Iteracyjna procedura wykorzystująca lokalną regresję wielomianową (loess) do estymacji trendu i sezonowości.
- Zalety:
 - Elastyczność – użytkownik kontroluje gładkość trendu i sezonowości.
 - Odporność na obserwacje nietypowe (wersja robust).
 - Może obsługiwać dowolną częstotliwość danych.
- Ograniczenia:
 - Tylko dekompozycja addytywna (multiplikatywną uzyskujemy przez logarytm).
 - Nie ma wbudowanego modelowania efektów kalendarzowych ani obserwacji nietypowych (w odróżnieniu od X-13 i TRAMO/SEATS).