

Modele ARMA

ASC 2026

Piotr Żoch

- Model AR
- Model MA
- Modele ARMA
- Prognozy

ARMA

- AR: *autoregressive*
- MA: *moving average*

$$y_t = a_0 + \underbrace{\sum_{i=1}^p a_i y_{t-i}}_{AR(p)} + \underbrace{\sum_{i=0}^q \theta_i \varepsilon_{t-i}}_{MA(q)}$$

gdzie $\theta_0 \equiv 1$.

- Stacjonarny proces ARMA

$$A(L) y_t = a_0 + \theta(L) \varepsilon_t$$

można zapisać jako

$$y_t = \sum_{j=0}^{\infty} \psi_j L^j \varepsilon_t + \kappa_t$$

$$\psi_0 = 1$$

gdzie κ_t jest składnikiem deterministycznym.

- Mnożnik dynamiczny mierzy efekt ε_t na wartości $\{y_{t+h}\}_{h=0}^{\infty}$:

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} = \frac{\partial y_h}{\partial \varepsilon_0} = \psi_h$$

- Funkcja reakcji na impuls to $\{\psi_h\}_{h=0}^{\infty}$ – mówi nam o tym, jak reagują wartości $\{y_{t+h}\}_{h=0}^{\infty}$ na jednorazowy impuls/szok ε_t .

- Mnożnik skumulowany: efekt permanentnej zmiany $\varepsilon_t = \varepsilon_{t+1} = \varepsilon_{t+2} = \dots$

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} + \frac{\partial y_{t+h}}{\partial \varepsilon_{t+1}} + \dots + \frac{\partial y_{t+h}}{\partial \varepsilon_{t+h}} = \sum_{j=0}^h \psi_{h-j}$$

- Dla $h \rightarrow \infty$ mamy $\sum_{j=0}^{\infty} \psi_j = \Psi(1)$, gdzie $\Psi(L) \equiv \sum_{j=0}^{\infty} \psi_j L^j$.

Model AR

- Model $AR(p)$ (rzędu p):

$$y_t = a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \dots + a_p y_{t-p} + \epsilon_t$$

gdzie ϵ_t i.i.d. z wartością oczekiwaną 0 i wariancją σ^2 .

- Przykład – AR(1)

$$y_t = \rho y_{t-1} + \epsilon_t$$

można zapisać jako

$$y_t = \epsilon_t + \rho\epsilon_{t-1} + \rho^2\epsilon_{t-2} + \dots$$

jeśli $|\rho| < 1$.

- Mamy

$$y_t = \epsilon_t + \rho\epsilon_{t-1} + \rho^2\epsilon_{t-2} + \dots$$

- Mnożnik dynamiczny:

$$\frac{\partial y_{t+h}}{\partial \epsilon_t} = \rho^h$$

- Mnożnik skumulowany:

$$1 + \rho + \rho^2 + \dots = \frac{1}{1 - \rho}$$

Model AR(p)

- Model AR(p) to

$$y_t = a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \dots + a_p y_{t-p} + \epsilon_t$$

- Możemy zbadać stabilność analizując pierwiastki *wielomianu opóźnień* (szczegółowa dyskusja wielomianów opóźnień na kolejnych zajęciach)

$$1 - a_1 L - a_2 L^2 - \dots - a_p L^p.$$

- Stabilność gdy wszystkie pierwiastki z spełniają $|z| > 1$ (są *poza* kołem jednostkowym).

Model $AR(p)$

- Inne spojrzenie na model $AR(p)$: niech

$$x_{1,t} = y_t, \quad x_{2,t} = y_{t-1}, \quad x_{3,t} = y_{t-2}, \quad \dots, \quad x_{p,t} = y_{t-p+1}.$$

- Możemy zapisać $AR(p)$ jako

$$\begin{bmatrix} x_{1,t} \\ x_{2,t} \\ x_{3,t} \\ \vdots \\ x_{p,t} \end{bmatrix} = \begin{bmatrix} a_0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} + \begin{bmatrix} a_1 & a_2 & \cdots & a_{p-1} & a_p \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix} \begin{bmatrix} x_{1,t-1} \\ x_{2,t-1} \\ x_{3,t-1} \\ \vdots \\ x_{p,t-1} \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \epsilon_t$$

- Sprawdźmy – pierwszy wiersz to

$$\underbrace{x_{1,t}}_{y_t} = a_0 + a_1 \underbrace{x_{1,t-1}}_{y_{t-1}} + a_2 \underbrace{x_{2,t-1}}_{y_{t-2}} + \dots + a_p \underbrace{x_{p,t-1}}_{y_{t-p}} + \epsilon_t.$$

- Drugi wiersz to

$$\underbrace{x_{2,t}}_{y_{t-1}} = \underbrace{x_{1,t-1}}_{y_{t-1}}.$$

- Kolejne wiersze są podobne do drugiego.

Model $AR(p)$

- W zwartej postaci:

$$x_t = c + A x_{t-1} + b \epsilon_t, \quad c = \begin{bmatrix} a_0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

- Ważne: występuje tylko pierwsze opóźnienie wektora x_t .
- Korzyść: możemy badać czy $AR(p)$ da się zapisać jako $MA(\infty)$, analizując macierz A . Iteracyjne podstawianie daje

$$x_t = \sum_{j=0}^{\infty} A^j b \epsilon_{t-j} + (\text{część deterministyczna}),$$

co zbiega, gdy wszystkie wartości własne A są co do modułu mniejsze od 1.

Model $AR(p)$ – momenty

- Wartość oczekiwana:

$$E[y_t] = a_0 + a_1 E[y_{t-1}] + a_2 E[y_{t-2}] + \dots + a_p E[y_{t-p}] + E[\epsilon_t],$$

gdzie $E[\epsilon_t] = 0$.

- Dla procesu stacjonarnego $E[y_t] = E[y_{t-1}] = \dots$, czyli

$$E[y_t] = \frac{a_0}{1 - a_1 - a_2 - \dots - a_p}.$$

- Równania **Yule'a-Walkera**: kowariancja $\gamma_k \equiv \text{Cov}(y_t, y_{t-k})$ spełnia

$$\gamma_k = a_1\gamma_{k-1} + \cdots + a_p\gamma_{k-p}, \quad k \geq 1$$

$$\gamma_0 = a_1\gamma_1 + \cdots + a_p\gamma_p + \sigma^2$$

- Korelacja:

$$\rho_k = a_1\rho_{k-1} + \cdots + a_p\rho_{k-p}$$

- Mnożniki (dla $k \geq 1$, przy konwencji $\psi_0 = 1$ oraz $\psi_j = 0$ dla $j < 0$):

$$\psi_k = a_1\psi_{k-1} + \cdots + a_p\psi_{k-p}$$

Model MA

- Model MA(q) (rzędu q):

$$y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

gdzie ϵ_t i.i.d. z wartością oczekiwaną 0 i wariancją σ^2 .

- Model średniej ruchomej (*moving average*) to średnia ważona procesu białego szumu z bieżącego oraz q poprzednich okresów.

- Trudność: jak oszacować parametry tego modelu?
 - Nie obserwujemy $\epsilon_t, \epsilon_{t-1}, \dots$ w danych.

- Momenty modelu MA(q) (przyjmując $\theta_0 \equiv 1$):

$$E[y_t] = \mu$$

$$\text{Var}[y_t] = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma^2$$

$$\text{Cov}[y_t, y_{t-k}] = \begin{cases} \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k} & k \leq q \\ 0 & k > q \end{cases}$$

- Rozważmy model MA(1)

$$\begin{aligned}y_t &= \epsilon_t + \theta_1 \epsilon_{t-1} \\ &= (1 + \theta_1 L) \epsilon_t\end{aligned}$$

- Można go zapisać jako

$$\epsilon_t = y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 y_{t-3} + \dots$$

jeśli $|\theta_1| < 1$.

- W tym wypadku mówimy, że model MA(1) jest **odwracalny** i można przedstawić MA(1) jako AR(∞).

- Momenty

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1}$$

to

$$\gamma_0 = (1 + \theta_1^2) \sigma^2$$

$$\gamma_1 = \theta_1 \sigma^2$$

- Autokorelacja

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2} = \frac{1/\theta_1}{1 + (1/\theta_1)^2}$$

- Dwa modele MA(1)

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1},$$

$$\text{Var}(\epsilon_t) = \sigma^2$$

$$y_t = \tilde{\epsilon}_t + \frac{1}{\theta_1} \tilde{\epsilon}_{t-1},$$

$$\text{Var}(\tilde{\epsilon}_t) = \theta_1^2 \sigma^2$$

mają identyczną strukturę drugich momentów (te same γ_0, γ_1 , a więc i ACF). Bez przeskalowania wariancji szoku γ_0 w obu modelach byłoby różne.

- Jeden z nich jest odwracalny, drugi nie.
- Ten odwracalny nazywamy **postacią fundamentalną** modelu MA(1).

Modele ARMA w praktyce

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \sum_{i=0}^q \theta_i \epsilon_{t-i}, \quad \theta_0 \equiv 1$$

- Jak dobrać (p, q) ?
 - Metoda Boxa-Jenkinsa (1970)
 - Kryteria informacyjne

- Idea: użyć wykresów ACF i PACF do identyfikacji rzędów p i q .

- Funkcja autokorelacji (*Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami oddalonymi od siebie o k okresów:

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}, \quad \rho_k \in [-1, 1].$$

- Funkcja autokorelacji cząstkowej (*Partial Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami oddalonymi od siebie o k okresów, bez uwzględnienia wpływu wszystkich obserwacji „pomiędzy”.
- Funkcja ta jest równa wyestymowanemu współczynnikowi α_k w modelu autoregresyjnym k -tego rzędu

$$y_t = \mu + \alpha_1 y_{t-1} + \cdots + \alpha_k y_{t-k} + \varepsilon_t.$$

- Idea: użyć wykresów ACF i PACF do identyfikacji rzędów p i q .
 - Dla MA: $\text{Cov}[y_t, y_{t-k}] = 0$ dla $k > q$, więc w ACF istotnych jest q pierwszych opóźnień.
 - Dla AR: w PACF istotnych jest p pierwszych opóźnień.

- Ustalenie wartości p i q na podstawie wykresu ACF i PACF.
- Estymacja parametrów modelu $\text{ARMA}(p, q)$.
- Weryfikacja modelu $\text{ARMA}(p, q)$:
 - Dla modelu $\text{ARMA}(p^*, q^*)$, gdzie $p^* \geq p$ i $q^* \geq q$, weryfikuje się istotność dodatkowych opóźnień.
 - Sprawdza się, czy występuje autokorelacja reszt.

- **Kryteria informacyjne:** wybrać specyfikację o wysokiej wartości logarytmu funkcji wiarygodności $\ell = \ln L$ i niskiej liczbie szacowanych parametrów $k = p + q + 1$ (tu liczymy wyraz wolny, ale nie σ^2 ; niektóre podręczniki używają $k = p + q + 2$).
- Najczęściej stosowane: Akaike'a (AIC), Schwarza (BIC) oraz Hannana-Quinna (HQIC):

$$AIC = -2 \frac{\ell}{T} + 2 \frac{k}{T}$$

$$BIC = -2 \frac{\ell}{T} + \frac{k}{T} \ln T$$

$$HQIC = -2 \frac{\ell}{T} + 2 \frac{k}{T} \ln(\ln T)$$

- Nagroda za dobre dopasowanie do danych, kara za liczbę parametrów.

- Polega na stopniowym upraszczaniu możliwie najogólniejszego modelu początkowego.
- Ograniczenia narzucane na model definiowane przez zagnieżdżone hipotezy:
 - H_0^K zawiera najwięcej ograniczeń, H_0^1 najmniej.
- Hipotezą alternatywną jest zawsze postać ogólna.

Metoda od ogólnego do szczegółowego

- Przykład – postać ogólna:

$$y_t = \beta_1 y_{t-1} + \beta_2 y_{t-2} + \epsilon_t$$

i postacie szczególne:

$$y_t = \beta_1 y_{t-1} + 0 \cdot y_{t-2} + \epsilon_t$$

$$y_t = 0 \cdot y_{t-1} + \beta_2 y_{t-2} + \epsilon_t$$

$$y_t = 0 \cdot y_{t-1} + 0 \cdot y_{t-2} + \epsilon_t$$

- Problem: w jakiej kolejności testować?
- W przypadku szeregów czasowych zazwyczaj zagnieżdżanie pod względem kolejności opóźnień.

- Test LR (*likelihood ratio*):

$$LR = -2[\ell(\theta_R) - \ell(\theta)]$$

gdzie $\ell(\theta_R)$ odpowiada modelowi z restrykcjami. Można użyć tylko w przypadku modeli zagnieżdżonych.

- Przy H_0 (restrykcje) statystyka testowa ma rozkład χ^2 z liczbą stopni swobody równą liczbie liniowo niezależnych restrykcji.

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \epsilon_t + \sum_{i=1}^q \theta_i \epsilon_{t-i}$$

Przyjmijmy, że znamy y_t oraz reszty e_t dla $t \leq T$ (po estymacji reszty e_t traktujemy jako obserwowalne przybliżenia nieobserwowalnych zaburzeń ϵ_t). Interesuje nas prognoza na okresy $T+1, T+2, \dots$

$$y_{T+1} = a_0 + \sum_{i=1}^p a_i y_{T+1-i} + \sum_{i=1}^q \theta_i e_{T+1-i} + \epsilon_{T+1}$$

czyli

$$E_T[y_{T+1}] = a_0 + \sum_{i=1}^p a_i y_{T+1-i} + \sum_{i=1}^q \theta_i e_{T+1-i}.$$

- Prognozy punktowe obliczamy w sposób rekurencyjny:

$$E_T[y_{T+2}] = a_0 + a_1 E_T[y_{T+1}] + \sum_{i=2}^p a_i y_{T+2-i} + \sum_{i=2}^q \theta_i e_{T+2-i}.$$

- Dla $k > p$ i $k > q$ mamy

$$E_T[y_{T+k}] = a_0 + \sum_{i=1}^p a_i E_T[y_{T+k-i}].$$

- Postać $MA(\infty)$:

$$y_t = \epsilon_t + \psi_1 \epsilon_{t-1} + \psi_2 \epsilon_{t-2} + \dots$$

- Błąd losowy prognozy:

$$y_{T+1} - E_T[y_{T+1}] = \epsilon_{T+1}$$

$$y_{T+2} - E_T[y_{T+2}] = \epsilon_{T+2} + \psi_1 \epsilon_{T+1}$$

i tak dalej:

$$y_{T+k} - E_T[y_{T+k}] = \epsilon_{T+k} + \sum_{i=1}^{k-1} \psi_i \epsilon_{T+k-i}.$$

- Ponieważ $Cov[\epsilon_t, \epsilon_s] = 0$ dla $s \neq t$ oraz $Var[\epsilon_t] = \sigma_\epsilon^2$, mamy

$$\sigma_k^2 = Var[y_{T+k} - E_T[y_{T+k}]] = \sigma_\epsilon^2 \left(1 + \sum_{i=1}^{k-1} \psi_i^2 \right).$$

- Nie uwzględnia to innych źródeł błędu prognozy (np. błędnej specyfikacji).
- σ_k^2 wykorzystujemy do stworzenia prognozy przedziałowej.