

# Modele ARMA: kontynuacja

ASC 2026

---

Piotr Żoch

- Operator i wielomian opóźnień
- AR i MA: dodatkowe właściwości
- SARIMA

## Operator i wielomian opóźnień

---

- Proces  $\{y_t\}$  jest **stacjonarny w sensie słabym** (*stacjonarność kowariancyjna*), gdy spełnione są trzy warunki:
  - $E[y_t] = \mu < \infty$ ,
  - $Var[y_t] = \sigma^2 < \infty$ ,
  - $Cov(y_t, y_{t+h}) = Cov(y_s, y_{s+h}) = \gamma_h$ .
- Intuicyjnie: właściwości procesu nie zmieniają się w czasie.
- Jeśli którykolwiek warunek nie jest spełniony, proces jest **niestacjonarny**.
- W praktyce zazwyczaj badamy stacjonarność w sensie słabym.

- Każdy stacjonarny (w sensie słabym) proces  $\{y_t\}$  można przedstawić jako

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t, \quad \psi_0 = 1, \quad \varepsilon_t \sim WN(0, \sigma^2),$$

gdzie:

- $\varepsilon_t$  jest białym szumem z wariancją  $\sigma^2$ ;
- $\sum_{j=0}^{\infty} \psi_j^2 < \infty$ ;
- $\kappa_t$  jest składnikiem deterministycznym;
- $\varepsilon_t = y_t - E[y_t \mid y_{t-1}, y_{t-2}, \dots]$ ;
- współczynniki  $\{\psi_j\}$  nie zależą od  $t$ , tylko od horyzontu  $j$ .

- Definicja (*lag operator*):

$$L^i y_t \equiv y_{t-i}.$$

- Właściwości:

- $L^i c = c$  dla stałej  $c$ ;
- $(L^i + L^j)y_t = L^i y_t + L^j y_t$ ;
- $L^{-i} y_t = y_{t+i}$  (*lead operator*);
- dla  $|a| < 1$ :

$$(1 + aL + a^2 L^2 + \dots) y_t = \frac{y_t}{1 - aL};$$

- dla  $|a| > 1$ :

$$[1 + (aL)^{-1} + (aL)^{-2} + \dots] y_t = -\frac{aL y_t}{1 - aL}.$$

- Niech

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_p L^p.$$

- $\theta(L)$  nazywamy **wielomianem opóźnień** (*lag polynomial*).
- Zachodzi

$$\theta(1) = 1 + \theta_1 + \theta_2 + \dots + \theta_p$$

$$\theta(L^2) = 1 + \theta_1 L^2 + \theta_2 L^4 + \dots + \theta_p L^{2p}.$$

## Wielomian opóźnień – mnożenie

Mamy dwa wielomiany opóźnień:

$$a(L) = 1 - aL, \quad b(L) = 1 - bL.$$

Wielomiany opóźnień mnożymy jak zwykłe wielomiany:

$$\begin{aligned} a(L) b(L) x_t &= (1 - aL)(1 - bL) x_t \\ &= (1 - (a + b)L + abL^2) x_t \\ &= x_t - (a + b) x_{t-1} + ab x_{t-2}. \end{aligned}$$



## Wielomian opóźnień – faktoryzacja

- Wielomiany opóźnień możemy dodawać i mnożyć jak zwykłe wielomiany.
- *Transformata z*: zamiast  $L$  można pracować na zmiennej  $z$  i *udać*, że mamy do czynienia ze zwykłym wielomianem, żeby znaleźć współczynniki czy pierwiastki wielomianu opóźnień.
- Każdy wielomian

$$a(L) = 1 + a_1L + a_2L^2 + \dots + a_pL^p$$

można zapisać jako

$$a(L) = (1 - \alpha_1L)(1 - \alpha_2L) \dots (1 - \alpha_pL),$$

gdzie  $\alpha_1^{-1}, \alpha_2^{-1}, \dots, \alpha_p^{-1}$  są pierwiastkami  $a(L)$ . Jeśli żaden pierwiastek nie leży w kole jednostkowym (czyli wszystkie  $|\alpha_k| < 1$ ), to istnieje rozwinięcie

$$a(L)^{-1} = (1 - \alpha_1L)^{-1}(1 - \alpha_2L)^{-1} \dots (1 - \alpha_pL)^{-1}.$$

## Wielomian opóźnień – przykład

- Rozważmy

$$x_t = -0,3 x_{t-1} + 0,1 x_{t-2} + u_t.$$

Możemy go zapisać jako

$$a(L) x_t = u_t,$$

gdzie

$$a(L) = 1 + 0,3L - 0,1L^2.$$

- Jakie są pierwiastki tego wielomianu?

- Wielomian

$$a(L) = 1 + 0,3L - 0,1L^2$$

można zapisać jako

$$a(L) = (1 + 0,5L)(1 - 0,2L),$$

czyli pierwiastki to  $L = -2$  i  $L = 5$  (oba poza kołem jednostkowym).

- Odwrotność:

$$a(L)^{-1} = (1 + 0,5L)^{-1}(1 - 0,2L)^{-1},$$

gdzie

$$(1 + 0,5L)^{-1} = 1 - 0,5L + 0,25L^2 - 0,125L^3 + \dots$$

$$(1 - 0,2L)^{-1} = 1 + 0,2L + 0,04L^2 + 0,008L^3 + \dots$$

- Mnożąc szeregi:

$$a(L)^{-1} = 1 - 0,3L + 0,19L^2 - 0,087L^3 + \dots$$

- Skoro

$$a(L) x_t = u_t,$$

to

$$\begin{aligned} x_t &= a(L)^{-1} u_t \\ &= u_t - 0,3 u_{t-1} + 0,19 u_{t-2} - 0,087 u_{t-3} + \cdots \end{aligned}$$

- Otrzymaliśmy w ten sposób reprezentację  $MA(\infty)$  procesu  $x_t$ .

# Model ARMA w zapisie operatorowym

- Stacjonarny model ARMA

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \sum_{i=0}^q \theta_i \varepsilon_{t-i}, \quad \theta_0 \equiv 1$$

możemy zapisać jako

$$A(L) y_t = a_0 + \Theta(L) \varepsilon_t,$$

gdzie  $A(L) = 1 - a_1 L - \dots - a_p L^p$  oraz  $\Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$ .

- Jeśli  $A(L)$  jest odwracalny:

$$y_t = A(L)^{-1} a_0 + \frac{\Theta(L)}{A(L)} \varepsilon_t = \kappa_t + \Psi(L) \varepsilon_t,$$

gdzie  $\Psi(L) = \Theta(L)/A(L) = \sum_{j=0}^{\infty} \psi_j L^j$  oraz  $\kappa_t$  jest składnikiem deterministycznym.

- Z dekompozycji Wolda dla stacjonarnego ARMA mamy

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t, \quad \psi_0 = 1.$$

- Współczynniki  $\{\psi_j\}$  otrzymujemy z  $\Psi(L) = \Theta(L)/A(L)$  – dokładnie tak jak w przykładzie z poprzednich slajdów.
- Są to mnożniki dynamiczne:

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} = \psi_h.$$

## AR i MA: dodatkowe właściwości

---



- Model  $AR(p)$ :

$$y_t = a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \dots + a_p y_{t-p} + \varepsilon_t.$$

- W zapisie operatorowym

$$(1 - a_1 L - a_2 L^2 - \dots - a_p L^p) y_t = a_0 + \varepsilon_t,$$

czyli

$$A(L) y_t = a_0 + \varepsilon_t.$$

- Jeśli wielomian  $A(L)$  jest odwracalny, to

$$\begin{aligned}y_t &= A(L)^{-1}(a_0 + \varepsilon_t) \\&= \mu + \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \cdots \\&= \mu + \Psi(L) \varepsilon_t,\end{aligned}$$

gdzie  $\mu = a_0/A(1)$ .

- To zapis modelu  $AR(p)$  jako  $MA(\infty)$ .

- Niech  $z_1, \dots, z_p$  będą pierwiastkami wielomianu opóźnień  $A(L)$ , czyli rozwiązaniami równania  $A(z) = 0$ .
- Jeśli wszystkie pierwiastki spełniają  $|z_k| > 1$  (są *poza* kołem jednostkowym), to model  $AR(p)$  jest **stabilny**.
- Stabilność  $\Rightarrow$  stacjonarność (w sensie słabym).
- Wtedy istnieje reprezentacja  $MA(\infty)$ :

$$y_t = \mu + \Psi(L) \varepsilon_t, \quad \lim_{j \rightarrow \infty} \psi_j = 0.$$

- Przykład – AR(1)

$$y_t = \rho y_{t-1} + \varepsilon_t$$

można zapisać jako

$$(1 - \rho L) y_t = \varepsilon_t.$$

- Jakie są pierwiastki wielomianu opóźnień?

- Mamy

$$1 - \rho z = 0 \iff z = \frac{1}{\rho},$$

więc stabilność (i tym samym stacjonarność) zachodzi gdy  $|1/\rho| > 1$ , czyli  $\rho \in (-1, 1)$ .

- Wtedy

$$\begin{aligned} y_t &= \frac{1}{1 - \rho L} \varepsilon_t \\ &= (1 + \rho L + \rho^2 L^2 + \dots) \varepsilon_t \\ &= \varepsilon_t + \rho \varepsilon_{t-1} + \rho^2 \varepsilon_{t-2} + \dots \end{aligned}$$

## Model AR(1) – mnożniki

- Mamy

$$y_t = \varepsilon_t + \rho \varepsilon_{t-1} + \rho^2 \varepsilon_{t-2} + \dots$$

- Mnożnik dynamiczny:

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} = \rho^h.$$

- Mnożnik skumulowany (dla  $|\rho| < 1$ ):

$$1 + \rho + \rho^2 + \dots = \frac{1}{1 - \rho}.$$

- Przykład – błądzenie losowe (*random walk*)

$$y_t = y_{t-1} + \varepsilon_t \quad \Longleftrightarrow \quad (1 - L)y_t = \varepsilon_t.$$

- Pierwiastek wielomianu opóźnień:  $z = 1$  – leży *na* kole jednostkowym.
- Brak stabilności i stacjonarności (*unit root*).
- Iteracyjne podstawianie:

$$y_t = y_0 + \sum_{j=1}^t \varepsilon_j, \quad \text{Var}(y_t) = t \sigma^2 \xrightarrow{t \rightarrow \infty} \infty.$$

- Motywacja dla modeli ARIMA – różnicowanie  $(1 - L)y_t$  usuwa pierwiastek jednostkowy.

## Model $AR(p)$ – pierwiastki wielomianu opóźnień

- Model  $AR(p)$ :

$$y_t = a_0 + a_1 y_{t-1} + \dots + a_p y_{t-p} + \varepsilon_t,$$

z wielomianem opóźnień

$$A(L) = 1 - a_1 L - a_2 L^2 - \dots - a_p L^p.$$

- Stabilność wtedy, gdy wszystkie pierwiastki z równania  $A(z) = 0$  leżą *poza* kołem jednostkowym,  $|z_k| > 1$ .



## Model $AR(p)$ – postać macierzowa

- Przypomnienie z poprzednich slajdów:  $AR(p)$  zapisujemy jako

$$x_t = c + A x_{t-1} + b \varepsilon_t,$$

gdzie  $x_t = (y_t, y_{t-1}, \dots, y_{t-p+1})'$ ,

$$c = \begin{bmatrix} a_0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

a  $A$  jest macierzą towarzyszącą.

- Ważne: w tym układzie występuje tylko **pierwsze** opóźnienie wektora  $x_t$ .

## Model $AR(p)$ – wartości własne a pierwiastki

- Iteracyjne podstawianie daje

$$x_t = \sum_{j=0}^{\infty} A^j (c + b \varepsilon_{t-j}),$$

co zbiega gdy wszystkie wartości własne  $\lambda_k$  macierzy  $A$  spełniają  $|\lambda_k| < 1$ .

- Wielomian charakterystyczny macierzy  $A$  to

$$\lambda^p - a_1 \lambda^{p-1} - a_2 \lambda^{p-2} - \dots - a_p = \lambda^p A(1/\lambda).$$

- Stąd: **wartości własne  $A$  to odwrotności pierwiastków** wielomianu opóźnień ( $\lambda_k = 1/z_k$ ).
- *Uwaga:* wartości własne **w** kole jednostkowym  $\Leftrightarrow$  pierwiastki wielomianu opóźnień **poza** kołem.

# SARIMA

---

- Model ARIMA( $p, d, q$ ):

$$\left(1 - \sum_{i=1}^p a_i L^i\right)(1 - L)^d y_t = \left(\sum_{i=0}^q \theta_i L^i\right) \varepsilon_t, \quad \theta_0 \equiv 1.$$

- Przykład – ARIMA(0, 1, 0):

$$(1 - L)y_t = \varepsilon_t \iff y_t - y_{t-1} = \varepsilon_t.$$

- Przykład – ARIMA(0, 2, 0):

$$(1 - L)^2 y_t = \varepsilon_t \iff (y_t - y_{t-1}) - (y_{t-1} - y_{t-2}) = \varepsilon_t.$$

- Korzystamy w przypadku niestacjonarnych danych.

# Dlaczego SARIMA?

- Wiele szeregów ekonomicznych wykazuje silną **sezonowość**:
  - miesięczna sprzedaż detaliczna (szczyt w grudniu),
  - kwartalne PKB i zatrudnienie,
  - miesięczne dane o ruchu lotniczym, zużyciu energii, turystyce.
- Zwykły ARIMA może nie wystarczyć: nawet po różnicowaniu pozostają wyraźne korelacje na opóźnieniach  $m, 2m, 3m, \dots$
- Pomysł: oprócz zwykłej dynamiki dodać *sezonowy* składnik AR/MA na opóźnieniach  $m, 2m, \dots$  oraz *sezonowe różnicowanie*  $(1 - L^m)$ .
- $m$  – długość cyklu sezonowego:  $m = 4$  dla danych kwartalnych,  $m = 12$  dla miesięcznych,  $m = 7$  dla danych dziennych z cyklem tygodniowym.

- Model SARIMA –  $\text{ARIMA}(p, d, q)(P, D, Q)_m$  to

$$\begin{aligned} \left(1 - \sum_{i=1}^p a_i L^i\right) \left(1 - \sum_{i=1}^P \varrho_i L^{im}\right) (1 - L)^d (1 - L^m)^D y_t \\ = \left(\sum_{i=0}^q \theta_i L^i\right) \left(\sum_{i=0}^Q \vartheta_i L^{im}\right) \varepsilon_t, \end{aligned}$$

gdzie  $\theta_0 \equiv \vartheta_0 \equiv 1$ , a  $m$  to długość cyklu sezonowego (np.  $m = 4$  dla danych kwartalnych,  $m = 12$  dla miesięcznych).

- Przykład: SARIMA(0, 0, 0)(1, 0, 0)<sub>4</sub>:

$$(1 - \varrho_1 L^4) y_t = \varepsilon_t \iff y_t = \varrho_1 y_{t-4} + \varepsilon_t.$$

- Przykład: SARIMA(1, 0, 0)(0, 1, 0)<sub>4</sub>:

$$(1 - \rho L)(1 - L^4) y_t = \varepsilon_t$$

$$(y_t - y_{t-4}) - \rho(y_{t-1} - y_{t-5}) = \varepsilon_t.$$

- Modele SARIMA pozwalają jednocześnie modelować zwykłą dynamikę (poprzez część niesezonową) oraz wahania sezonowe (poprzez część sezonową).

# Model linii lotniczych

- Klasyczny przykład z Boxa i Jenkinsa (1976) – miesięczna liczba pasażerów lotniczych:

$$\text{ARIMA}(0, 1, 1)(0, 1, 1)_{12}.$$

- Postać:

$$(1 - L)(1 - L^{12})y_t = (1 + \theta_1 L)(1 + \vartheta_1 L^{12})\varepsilon_t.$$

- Składowe:

- $(1 - L)$  – różnicowanie zwykłe usuwa trend,
  - $(1 - L^{12})$  – różnicowanie sezonowe usuwa coroczny wzorec,
  - $(1 + \theta_1 L)$  – MA(1) opisuje krótkookresową dynamikę,
  - $(1 + \vartheta_1 L^{12})$  – sezonowe MA(1) opisuje wahania rok-do-roku.
- Tylko dwa parametry, a model dobrze opisuje wiele szeregów miesięcznych.



# Identyfikacja SARIMA

- Box-Jenkins dla SARIMA: patrzymy na ACF i PACF *na opóźnieniach sezonowych*  $m, 2m, 3m, \dots$
- Analogicznie jak dla ARMA:
  - ACF gaśnie wykładniczo na opóźnieniach  $m, 2m, \dots$ , PACF urywa się po  $Pm \Rightarrow$  sezonowe AR( $P$ );
  - ACF urywa się po  $Qm$ , PACF gaśnie wykładniczo na opóźnieniach  $m, 2m, \dots \Rightarrow$  sezonowe MA( $Q$ ).
- Powolne wygasanie ACF na  $m, 2m, \dots$  sugeruje niestacjonarność sezonową  $\Rightarrow$  rozważyć  $D = 1$ .
- W praktyce: najpierw dobieramy stopnie różnicowania  $d, D$ , potem rzędy  $p, q, P, Q$ .
- Kryteria informacyjne (AIC, BIC) i diagnostyka reszt – tak samo jak w ARMA.