

Modele ARMA: kontynuacja

ASC 2026

Piotr Żoch

- Operator i wielomian opóźnień
- AR i MA: dodatkowe właściwości
- SARIMA

Operator i wielomian opóźnień

- Proces $\{y_t\}$ jest **stacjonarny w sensie słabym** (*stacjonarność kowariancyjna*), gdy spełnione są trzy warunki:
 - $E[y_t] = \mu < \infty$,
 - $Var[y_t] = \sigma^2 < \infty$,
 - $Cov(y_t, y_{t+h}) = Cov(y_s, y_{s+h}) = \gamma_h$.
- Intuicyjnie: właściwości procesu nie zmieniają się w czasie.
- Jeśli którykolwiek warunek nie jest spełniony, proces jest **niestacjonarny**.
- W praktyce zazwyczaj badamy stacjonarność w sensie słabym.

- **Twierdzenie Wolda.** Każdy kowariancyjnie stacjonarny proces $\{y_t\}$ (po odjęciu średniej) można rozłożyć na część *liniowo deterministyczną* κ_t oraz czysto *niedeterministyczną* $MA(\infty)$:

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t, \quad \psi_0 = 1, \quad \varepsilon_t \sim WN(0, \sigma^2),$$

gdzie:

- ε_t jest białym szumem z wariancją σ^2 ;
- $\sum_{j=0}^{\infty} \psi_j^2 < \infty$;
- κ_t jest częścią liniowo deterministyczną;
- $\varepsilon_t = y_t - P[y_t \mid y_{t-1}, y_{t-2}, \dots]$, gdzie $P[\cdot \mid \cdot]$ oznacza *projekcję liniową*;
- współczynniki $\{\psi_j\}$ nie zależą od t , tylko od horyzontu j .

- Definicja (*lag operator*):

$$L^i y_t \equiv y_{t-i}.$$

- Właściwości:

- $L^i c = c$ dla stałej c ;
- $(L^i + L^j)y_t = L^i y_t + L^j y_t$;
- $L^{-i} y_t = y_{t+i}$ (*lead operator*);
- dla $|a| < 1$:

$$(1 + aL + a^2 L^2 + \dots) y_t = (1 - aL)^{-1} y_t;$$

- dla $|a| > 1$:

$$[1 + (aL)^{-1} + (aL)^{-2} + \dots] y_t = -aL(1 - aL)^{-1} y_t.$$

- Niech

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_p L^p.$$

- $\theta(L)$ nazywamy **wielomianem opóźnień** (*lag polynomial*).
- Zachodzi

$$\theta(1) = 1 + \theta_1 + \theta_2 + \cdots + \theta_p$$

$$\theta(L^2) = 1 + \theta_1 L^2 + \theta_2 L^4 + \cdots + \theta_p L^{2p}.$$

Wielomian opóźnień – mnożenie

Mamy dwa wielomiany opóźnień:

$$a(L) = 1 - aL, \quad b(L) = 1 - bL.$$

Wielomiany opóźnień mnożymy jak zwykłe wielomiany:

$$\begin{aligned} a(L) b(L) x_t &= (1 - aL)(1 - bL) x_t \\ &= (1 - (a + b)L + abL^2) x_t \\ &= x_t - (a + b) x_{t-1} + ab x_{t-2}. \end{aligned}$$

Wielomian opóźnień – faktoryzacja

- Wielomiany opóźnień możemy dodawać i mnożyć jak zwykłe wielomiany.
- *Transformata z*: zamiast L pracujemy na zmiennej z i *udajemy*, że mamy zwykły wielomian – np. żeby znaleźć jego pierwiastki.
- Każdy wielomian

$$a(L) = 1 + a_1L + a_2L^2 + \dots + a_pL^p$$

można zapisać jako

$$a(L) = (1 - \alpha_1L)(1 - \alpha_2L) \dots (1 - \alpha_pL),$$

gdzie $\alpha_1^{-1}, \alpha_2^{-1}, \dots, \alpha_p^{-1}$ są pierwiastkami $a(L)$. Jeśli wszystkie pierwiastki z_k równania $a(z) = 0$ leżą *poza* kołem jednostkowym ($|z_k| > 1$, równoważnie $|\alpha_k| < 1$), to istnieje zbieżne rozwinięcie

$$a(L)^{-1} = (1 - \alpha_1L)^{-1}(1 - \alpha_2L)^{-1} \dots (1 - \alpha_pL)^{-1}.$$

Wielomian opóźnień – przykład

- Rozważmy

$$x_t = -0,3 x_{t-1} + 0,1 x_{t-2} + u_t.$$

Możemy go zapisać jako

$$a(L) x_t = u_t,$$

gdzie

$$a(L) = 1 + 0,3L - 0,1L^2.$$

- Jakie są pierwiastki tego wielomianu?

- Wielomian

$$a(L) = 1 + 0,3L - 0,1L^2$$

można zapisać jako

$$a(L) = (1 + 0,5L)(1 - 0,2L),$$

czyli pierwiastki to $L = -2$ i $L = 5$ (oba poza kołem jednostkowym).

Wielomian opóźnień – przykład

- Odwrotność:

$$a(L)^{-1} = (1 + 0,5L)^{-1}(1 - 0,2L)^{-1},$$

gdzie

$$(1 + 0,5L)^{-1} = 1 - 0,5L + 0,25L^2 - 0,125L^3 + \dots$$

$$(1 - 0,2L)^{-1} = 1 + 0,2L + 0,04L^2 + 0,008L^3 + \dots$$

- Mnożąc szeregi:

$$a(L)^{-1} = 1 - 0,3L + 0,19L^2 - 0,087L^3 + \dots$$

- Skoro

$$a(L) x_t = u_t,$$

to

$$\begin{aligned} x_t &= a(L)^{-1} u_t \\ &= u_t - 0,3 u_{t-1} + 0,19 u_{t-2} - 0,087 u_{t-3} + \cdots \end{aligned}$$

- Otrzymaliśmy w ten sposób reprezentację $MA(\infty)$ procesu x_t .

Model ARMA w zapisie operatorowym

- Stacjonarny model ARMA

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \sum_{i=0}^q \theta_i \varepsilon_{t-i}, \quad \theta_0 \equiv 1$$

możemy zapisać jako

$$A(L) y_t = a_0 + \Theta(L) \varepsilon_t,$$

gdzie $A(L) = 1 - a_1 L - \dots - a_p L^p$ oraz $\Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$.

- Jeśli model jest stabilny (pierwiastki $A(z) = 0$ leżą poza kołem jednostkowym):

$$y_t = A(L)^{-1} a_0 + \frac{\Theta(L)}{A(L)} \varepsilon_t = \mu + \Psi(L) \varepsilon_t,$$

gdzie $\mu = a_0/A(1)$ oraz $\Psi(L) = \Theta(L)/A(L) = \sum_{j=0}^{\infty} \psi_j L^j$.

- Z dekompozycji Wolda dla stacjonarnego ARMA mamy

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t, \quad \psi_0 = 1.$$

- Współczynniki $\{\psi_j\}$ otrzymujemy z $\Psi(L) = \Theta(L)/A(L)$ – dokładnie tak jak w przykładzie z poprzednich slajdów.
- Są to mnożniki dynamiczne:

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} = \psi_h.$$

AR i MA: dodatkowe właściwości

- Model $AR(p)$:

$$y_t = a_0 + a_1 y_{t-1} + a_2 y_{t-2} + \dots + a_p y_{t-p} + \varepsilon_t.$$

- W zapisie operatorowym

$$(1 - a_1 L - a_2 L^2 - \dots - a_p L^p) y_t = a_0 + \varepsilon_t,$$

czyli

$$A(L) y_t = a_0 + \varepsilon_t.$$

- Jeśli model jest stabilny (pierwiastki $A(z) = 0$ leżą poza kołem jednostkowym), to

$$\begin{aligned}y_t &= A(L)^{-1}(a_0 + \varepsilon_t) \\&= \mu + \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \cdots \\&= \mu + \Psi(L) \varepsilon_t,\end{aligned}$$

gdzie $\mu = a_0/A(1)$.

- To zapis modelu $AR(p)$ jako $MA(\infty)$.

- Niech $z_1, \dots, z_p$ będą pierwiastkami wielomianu opóźnień $A(L)$, czyli rozwiązaniami równania $A(z) = 0$.
- Jeśli wszystkie pierwiastki spełniają $|z_k| > 1$ (są *poza* kołem jednostkowym), to model $AR(p)$ jest **stabilny**.
- Stabilność $\Rightarrow$ stacjonarność (w sensie słabym), przy założeniu, że ε_t jest białym szumem o skończonej wariancji.
- Wtedy istnieje reprezentacja $MA(\infty)$:

$$y_t = \mu + \Psi(L) \varepsilon_t, \quad \sum_{j=0}^{\infty} |\psi_j| < \infty.$$

Stabilność AR vs. odwracalność MA

- Dwa pokrewne, ale **różne** pojęcia – oba dotyczą pierwiastków pewnego wielomianu poza kołem jednostkowym:
 - **Stabilność (przyczynowość) AR**: pierwiastki $A(z) = 0$ leżą poza kołem jednostkowym. Wtedy AR ma reprezentację $MA(\infty)$: $y_t = \Psi(L) \varepsilon_t$.
 - **Odwracalność MA**: pierwiastki $\Theta(z) = 0$ leżą poza kołem jednostkowym. Wtedy MA ma reprezentację $AR(\infty)$: $\Pi(L) y_t = \varepsilon_t$.
- Różnica: **który** wielomian i **w którą stronę** idzie reprezentacja.
- Dla modelu ARMA wymagamy *obu*: stabilności części AR oraz odwracalności części MA – żeby model był jednoznacznie identyfikowalny i miał reprezentację $MA(\infty)$ ze zbieżnymi wagami.

- Przykład – AR(1)

$$y_t = \rho y_{t-1} + \varepsilon_t$$

można zapisać jako

$$(1 - \rho L) y_t = \varepsilon_t.$$

- Jakie są pierwiastki wielomianu opóźnień?

Model AR(1)

- Mamy (dla $\rho \neq 0$)

$$1 - \rho z = 0 \iff z = \frac{1}{\rho},$$

więc stabilność (i tym samym stacjonarność) zachodzi, gdy $|1/\rho| > 1$, czyli $\rho \in (-1, 1)$. Dla $\rho = 0$ proces jest trywialnie stacjonarny: $y_t = \varepsilon_t$.

- Wtedy

$$\begin{aligned} y_t &= \frac{1}{1 - \rho L} \varepsilon_t \\ &= (1 + \rho L + \rho^2 L^2 + \dots) \varepsilon_t \\ &= \varepsilon_t + \rho \varepsilon_{t-1} + \rho^2 \varepsilon_{t-2} + \dots \end{aligned}$$

- Mamy

$$y_t = \varepsilon_t + \rho \varepsilon_{t-1} + \rho^2 \varepsilon_{t-2} + \dots$$

- Mnożnik dynamiczny:

$$\frac{\partial y_{t+h}}{\partial \varepsilon_t} = \rho^h.$$

- Mnożnik skumulowany (dla $|\rho| < 1$):

$$1 + \rho + \rho^2 + \dots = \frac{1}{1 - \rho}.$$

- Przykład – błądzenie losowe (*random walk*)

$$y_t = y_{t-1} + \varepsilon_t \quad \Longleftrightarrow \quad (1 - L)y_t = \varepsilon_t.$$

- Pierwiastek wielomianu opóźnień: $z = 1$ – leży *na* kole jednostkowym.
- Brak stabilności i stacjonarności (*unit root*).
- Iteracyjne podstawianie (przy deterministycznym y_0):

$$y_t = y_0 + \sum_{j=1}^t \varepsilon_j, \quad \text{Var}(y_t) = t \sigma^2 \xrightarrow{t \rightarrow \infty} \infty.$$

- Motywacja dla modeli ARIMA – różnicowanie $(1 - L)y_t$ usuwa pierwiastek jednostkowy.

Model $AR(p)$ – pierwiastki wielomianu opóźnień

- Model $AR(p)$:

$$y_t = a_0 + a_1 y_{t-1} + \dots + a_p y_{t-p} + \varepsilon_t,$$

z wielomianem opóźnień

$$A(L) = 1 - a_1 L - a_2 L^2 - \dots - a_p L^p.$$

- Stabilność wtedy, gdy wszystkie pierwiastki z równania $A(z) = 0$ leżą *poza* kołem jednostkowym, $|z_k| > 1$.

Model $AR(p)$ – postać macierzowa

- Przypomnienie z poprzednich slajdów: $AR(p)$ zapisujemy jako

$$x_t = c + A x_{t-1} + b \varepsilon_t,$$

gdzie $x_t = (y_t, y_{t-1}, \dots, y_{t-p+1})'$,

$$c = \begin{bmatrix} a_0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

a A jest macierzą towarzyszącą.

- Ważne: w tym układzie występuje tylko **pierwsze** opóźnienie wektora x_t .

Model $AR(p)$ – wartości własne a pierwiastki

- Iteracyjne podstawianie daje

$$x_t = \sum_{j=0}^{\infty} A^j (c + b \varepsilon_{t-j}),$$

co zbiega gdy wszystkie wartości własne λ_k macierzy A spełniają $|\lambda_k| < 1$.

- Wielomian charakterystyczny macierzy A to

$$\lambda^p - a_1 \lambda^{p-1} - a_2 \lambda^{p-2} - \dots - a_p = \lambda^p A(1/\lambda).$$

- Stąd: **wartości własne A to odwrotności pierwiastków** wielomianu opóźnień ($\lambda_k = 1/z_k$).
- *Uwaga:* wartości własne **w** kole jednostkowym $\Leftrightarrow$ pierwiastki wielomianu opóźnień **poza** kołem.

SARIMA

- Model ARIMA(p, d, q):

$$\left(1 - \sum_{i=1}^p a_i L^i\right)(1 - L)^d y_t = \left(\sum_{i=0}^q \theta_i L^i\right) \varepsilon_t, \quad \theta_0 \equiv 1.$$

- Przykład – ARIMA(0, 1, 0):

$$(1 - L)y_t = \varepsilon_t \iff y_t - y_{t-1} = \varepsilon_t.$$

- Przykład – ARIMA(0, 2, 0):

$$(1 - L)^2 y_t = \varepsilon_t \iff (y_t - y_{t-1}) - (y_{t-1} - y_{t-2}) = \varepsilon_t.$$

- Korzystamy w przypadku niestacjonarnych danych.

Dlaczego SARIMA?

- Wiele szeregów ekonomicznych wykazuje silną **sezonowość**:
 - miesięczna sprzedaż detaliczna (szczyt w grudniu),
 - kwartalne PKB i zatrudnienie,
 - miesięczne dane o ruchu lotniczym, zużyciu energii, turystyce.
- Zwykły ARIMA może nie wystarczyć: nawet po różnicowaniu pozostają wyraźne korelacje na opóźnieniach $m, 2m, 3m, \dots$
- Pomysł: oprócz zwykłej dynamiki dodać *sezonowy* składnik AR/MA na opóźnieniach $m, 2m, \dots$ oraz *sezonowe różnicowanie* $(1 - L^m)$.
- m – długość cyklu sezonowego: $m = 4$ dla danych kwartalnych, $m = 12$ dla miesięcznych, $m = 7$ dla danych dziennych z cyklem tygodniowym.

- Model SARIMA – $\text{ARIMA}(p, d, q)(P, D, Q)_m$ to

$$\begin{aligned} \left(1 - \sum_{i=1}^p a_i L^i\right) \left(1 - \sum_{i=1}^P \varrho_i L^{im}\right) (1 - L)^d (1 - L^m)^D y_t \\ = \left(\sum_{i=0}^q \theta_i L^i\right) \left(\sum_{i=0}^Q \vartheta_i L^{im}\right) \varepsilon_t, \end{aligned}$$

gdzie $\theta_0 \equiv \vartheta_0 \equiv 1$, a m to długość cyklu sezonowego (np. $m = 4$ dla danych kwartalnych, $m = 12$ dla miesięcznych).

- Przykład: SARIMA(0, 0, 0)(1, 0, 0)₄:

$$(1 - \varrho_1 L^4) y_t = \varepsilon_t \iff y_t = \varrho_1 y_{t-4} + \varepsilon_t.$$

- Przykład: SARIMA(1, 0, 0)(0, 1, 0)₄:

$$(1 - \rho L)(1 - L^4) y_t = \varepsilon_t$$

$$(y_t - y_{t-4}) - \rho(y_{t-1} - y_{t-5}) = \varepsilon_t.$$

- Modele SARIMA pozwalają jednocześnie modelować zwykłą dynamikę (poprzez część niesezonową) oraz wahania sezonowe (poprzez część sezonową).

Model linii lotniczych

- Klasyczny przykład z Boxa i Jenkinsa (1976) – logarytm miesięcznej liczby pasażerów lotniczych:

$$\log y_t \sim \text{ARIMA}(0, 1, 1)(0, 1, 1)_{12}.$$

- Postać:

$$(1 - L)(1 - L^{12}) \log y_t = (1 + \theta_1 L)(1 + \vartheta_1 L^{12}) \varepsilon_t.$$

- Składowe:

- $(1 - L)$ – różnicowanie zwykłe usuwa trend,
 - $(1 - L^{12})$ – różnicowanie sezonowe usuwa coroczny wzorec,
 - $(1 + \theta_1 L)$ – MA(1) opisuje krótkookresową dynamikę,
 - $(1 + \vartheta_1 L^{12})$ – sezonowe MA(1) opisuje wahania rok-do-roku.
- Tylko dwa parametry, a model dobrze opisuje wiele szeregów miesięcznych.

Identyfikacja SARIMA

- Box-Jenkins dla SARIMA: patrzymy na ACF i PACF *na opóźnieniach sezonowych* $m, 2m, 3m, \dots$
- Analogicznie jak dla ARMA:
 - ACF gaśnie wykładniczo na opóźnieniach $m, 2m, \dots$, PACF urywa się po $Pm \Rightarrow$ sezonowe $AR(P)$;
 - ACF urywa się po Qm , PACF gaśnie wykładniczo na opóźnieniach $m, 2m, \dots \Rightarrow$ sezonowe $MA(Q)$.
- Powolne wygasanie ACF na $m, 2m, \dots$ sugeruje niestacjonarność sezonową $\Rightarrow$ rozważyć $D = 1$.
- W praktyce: najpierw dobieramy stopnie różnicowania d, D , potem rzędy p, q, P, Q .
- Kryteria informacyjne (AIC, BIC) i diagnostyka reszt – tak samo jak w ARMA.