

Kointegracja i VECM

ASC 2026

Piotr Żoch

- Regresja pozorna
- Kointegracja
- Testowanie kointegracji
- ECM
- VECM

Kointegracja

Modelowanie zależności między niepowiązanymi zmiennymi niestacjonarnymi może prowadzić do regresji pozornej:

$$x_t = x_{t-1} + \varepsilon_t,$$

$$y_t = y_{t-1} + \nu_t.$$

W regresji

$$y_t = \alpha + \beta x_t + u_t$$

często otrzymujemy wysokie R^2 i istotne statystyki t , mimo że zmienne są niezależne.

- Typowa reakcja: różnicowanie.
- Problem: różnicowanie może wyrzucić informację o długookresowej równowadze.

Wspólny trend stochastyczny

Zmienne mogą być niestacjonarne, ale mieć wspólny trend:

$$x_t = Z_t + \varepsilon_t,$$

$$y_t = Z_t + \nu_t,$$

$$Z_t = Z_{t-1} + \zeta_t.$$

Wtedy

$$x_t - y_t = \varepsilon_t - \nu_t.$$

- x_t i y_t są $I(1)$.
- Różnica $x_t - y_t$ może być $I(0)$.
- Krótkookresowo zmienne mogą się od siebie oddalać, ale długookresowo poruszają się razem.

Niech $x_t = (x_{1t}, \dots, x_{nt})'$ będzie wektorem zmiennych $I(d)$.

Jeśli istnieje niezerowy wektor $\beta = (\beta_1, \dots, \beta_n)'$, taki że

$$\beta'x_t \sim I(d - b), \quad b > 0,$$

to zmienne są skointegrowane stopnia (d, b) .

- W praktyce najczęściej: $d = b = 1$.
- Wtedy kombinacja liniowa zmiennych $I(1)$ jest stacjonarna.
- β nazywamy wektorem kointegrującym.

- Kointegracja dotyczy kombinacji liniowej.
- Jeśli β jest wektorem kointegrującym, to $\lambda\beta$ dla $\lambda \neq 0$ też nim jest.
- Dlatego zwykle normalizujemy jeden parametr, np. przyjmujemy współczynnik przy y_t równy 1.
- Dla n zmiennych może istnieć najwyżej $n - 1$ liniowo niezależnych wektorów kointegrujących.
- Liczba takich wektorów to rząd kointegracji.

Jeśli y_t i x_t są skointegrowane, to w regresji

$$y_t = \alpha + \beta x_t + u_t$$

reszta u_t jest stacjonarna.

- Interpretacja: u_t to odchylenie od długookresowej równowagi.
- Gdy y_t oddala się od $\alpha + \beta x_t$, system ma tendencję do powrotu.
- Estymator MNK relacji długookresowej jest super-zgodny, ale standardowe rozkłady statystyk nie działają bezpośrednio.

Jeśli zmienne są skointegrowane, regresja na różnicach:

$$\Delta y_t = \gamma \Delta x_t + e_t$$

opisuje tylko zależność krótkookresową.

- Tracimy informację o poziomie równowagi.
- Możemy otrzymać obciążony obraz zależności długookresowej.
- Potrzebujemy modelu, który zawiera:
 - krótkookresową dynamikę w różnicach,
 - korektę odchylenia od równowagi.

Testowanie kointegracji

Testowanie kointegracji

Podstawowy schemat:

1. Sprawdź stopień integracji zmiennych.
2. Jeśli zmienne są $I(0)$, kointegracja nie jest potrzebna.
3. Jeśli zmienne są zintegrowane różnego stopnia, nie mogą być skointegrowane w standardowym sensie.
4. Jeśli zmienne są $I(1)$, testuj stacjonarność relacji długookresowej.

Wybór testu:

- dwie zmienne: Engle–Granger,
- wiele zmiennych i możliwy rząd kointegracji większy niż 1: Johansen.

Krok 1: oszacuj relację długookresową:

$$y_t = \alpha + \beta x_t + u_t.$$

Krok 2: testuj pierwiastek jednostkowy w resztach:

$$\Delta \hat{u}_t = \rho \hat{u}_{t-1} + \sum_{i=1}^k \phi_i \Delta \hat{u}_{t-i} + e_t.$$

$$H_0 : \rho = 0 \quad H_1 : \rho < 0.$$

Odrzucenie H_0 sugeruje kointegrację.

- Nie używamy zwykłych wartości krytycznych z testu ADF.
- Reszty $\hat{u}_t$ są konstruowane po estymacji α i β .
- Wartości krytyczne zależą od:
 - liczby zmiennych,
 - deterministycznych składników w relacji długookresowej,
 - trendu lub dryfu w zmiennych.
- Test Engle–Granger zakłada jeden wektor kointegrujący i jest wrażliwy na wybór zmiennej po lewej stronie.

Test Johansena wychodzi od reprezentacji VECM:

$$\Delta y_t = \Pi y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \Phi D_t + \varepsilon_t.$$

Kluczowy obiekt:

$$r = \text{rank}(\Pi).$$

- $r = 0$: brak kointegracji.
- $0 < r < n$: istnieje r relacji kointegrujących.
- $r = n$: zmienne są stacjonarne w poziomach.

Jeśli $0 < r < n$, macierz Π można rozłożyć jako

$$\Pi = \alpha\beta',$$

gdzie:

- β zawiera wektory kointegrujące,
- $\beta'y_{t-1}$ to odchylenia od równowagi długookresowej,
- α opisuje tempo dostosowania poszczególnych zmiennych do tych odchyleń.

Testy Johansena sprawdzają kolejne hipotezy o rzędzie r .

ECM i VECM

Twierdzenie Grangera o reprezentacji:

jeśli y_t i x_t są $I(1)$ oraz skointegrowane, to zależność między nimi można przedstawić jako ECM:

$$\Delta y_t = \kappa + \sum_{i=0}^{K-1} \gamma_i \Delta x_{t-i} + \sum_{i=1}^{L-1} \theta_i \Delta y_{t-i} + \delta(y_{t-1} - \alpha - \beta x_{t-1}) + \varepsilon_t.$$

- Część w różnicach: dynamika krótkookresowa.
- Nawias: odchylenie od równowagi długookresowej.

Niech

$$e_t = y_t - \alpha - \beta x_t.$$

W ECM:

$$\Delta y_t = \kappa + \delta e_{t-1} + \dots + \varepsilon_t.$$

- e_{t-1} mierzy odchylenie od równowagi.
- δ opisuje tempo powrotu do równowagi.
- Zwykle oczekujemy $\delta < 0$ w równaniu dla Δy_t .
- Przybliżony okres połowicznego wygaśnięcia:

$$-\frac{\ln 2}{\ln(1 + \delta)}.$$

Startujemy od VAR(p):

$$y_t = A_1 y_{t-1} + \dots + A_p y_{t-p} + \varepsilon_t.$$

Po odjęciu y_{t-1} i przekształceniu:

$$\Delta y_t = \Pi y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \varepsilon_t,$$

gdzie

$$\Pi = A_1 + \dots + A_p - I.$$

- To jest VECM: vector error correction model.

Gdy zmienne są skointegrowane:

$$\Pi = \alpha\beta'.$$

$$\Delta y_t = \alpha\beta'y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \Phi D_t + \varepsilon_t.$$

- $\beta'y_{t-1}$: relacje długookresowe.
- α : prędkości dostosowania.
- Γ_i : krótkookresowa dynamika.
- D_t : stała, trend, sezonowość, zmienne interwencyjne.

VAR, różnice czy VECM?

Dane	Relacje długookresowe	Model
$I(0)$	nie dotyczy	VAR w poziomach
$I(1)$	brak kointegracji	VAR w różnicach
$I(1)$	kointegracja	VECM

- VAR w poziomach może być dobry prognostycznie, ale wymaga ostrożnej inferencji.
- VECM łączy krótkookresową dynamikę z długookresową równowagą.

R: podstawowy schemat

```
library(vars)
library(urca)

# 1. stopien integracji
summary(ur.df(y[, "m"], type = "drift", lags = 4))
summary(ur.df(y[, "p"], type = "drift", lags = 4))

# 2. test Johansena i estymacja VECM
jo <- ca.jo(y, type = "trace", ecdet = "const", K = 4)
summary(jo)
vecm <- cajorls(jo, r = 1)

# 3. VAR odpowiadajacy VECM, np. do IRF
var_from_vecm <- vec2var(jo, r = 1)
```

Najważniejsze wnioski

- Regresja niestacjonarnych zmiennych może być pozorna.
- Kointegracja oznacza, że pewna kombinacja liniowa zmiennych $I(1)$ jest stacjonarna.
- Test Engle–Granger działa dla prostej relacji długookresowej.
- Test Johansena pozwala badać rząd kointegracji w układzie wielu zmiennych.
- VECM łączy krótkookresową dynamikę z korektą błędem.